

# Машинное обучение (Machine Learning)

Деформирующие автокодеры и распутывание  
(Deforming autoencoders - DAE and Disentangling)

Уткин Л.В.



## Порождающие модели

- ① Вариационные Автокодеры - Variational Autoencoders – VAE
  - ② Генеративные состязательные нейросети - Generative Adversarial Networks - GAN
  - ③ Деформирующие Автокодеры - Deforming autoencoders - DAE

# Классические автокодеры

- Могут обучаться для генерации компактных представлений
- Хорошо восстанавливают исходные данные
- Но фундаментальной проблемой автокодеров является то, что скрытое пространство, в котором они кодируют входные данные, может не быть непрерывным и не допускать гладкой интерполяции!

# Вариационные Автокодеры (VAE)

- Могут решить эту проблему, так как их скрытое пространство является непрерывным и позволяет легко производить случайную выборку и интерполяцию
- Но управление глубокими нейронными сетями и, в особенности, глубокими автокодерами - сложная задача, ключевая особенность которой — строгий контроль процесса обучения

# Деформирующий автокодер

- Это - породающая модель анализа изображений, которая выделяет признаки без дополнительных подсказок, предполагая создавать экземпляры объектов посредством деформации “шаблонного” объекта.
- Это означает, что вариативность объекта может быть разделена на уровни, связанные с пространственными трансформациями формы объекта.
- Z. Shu et al. **Deforming Autoencoders: Unsupervised Disentangling of Shape and Appearance** // arXiv:1806.06503, Jun. 2018.

# Disentangling (распутывание)



## О понятии Disentangling (распутывание)


- Предположим, что следующие векторы являются соответственно представлениями для мяча:  $[1,0,0,0]$  и автомобиля:  $[0,1,0,0]$
  - В этом представлении один нейрон узнает значение мяча или автомобиля, не полагаясь на другие нейроны. Это распутанное представление.

*Распутанные представления в интуитивном смысле означают, что скрытые факторы, которые изучает нейронная сеть, имеют семантическое значение.*

# Распутывание (1)

- Центральная мотивация распутанных представлений - идентификацию элементарных “строительных блоков” окружающего нас мира, которые неявно хранятся в данных.
- Эти “блоки” считаются инвариантными к изменениям, что делает их полезными для любой последующей задачи.
- Т.о. распутанное представление обычно предполагается как представление, которое отделяет или распутывает лежащую в основе структуру мира на непересекающиеся части его представления.

# Распутывание (2)



Слева - моделирование среды робота. Объект в среде представляет собой синий куб, поэтому распутанное представление может рассматривать непересекающиеся свойства цвета (синий) и формы (куб).


# Распутывание (3)

- Например, это означает, что для трехмерной сцены с объектами скрытое представление должно отдельно кодировать размер, цвет, форму и положение.
- Распутывание было расплывчатой концепцией, которой интересовались многие, но не могли выразить ее явно.
- Что означает понятие “семантически значимые (meaningful) скрытые представления”.

## Распутывание снов

- Визуально это то, что мы ожидаем: для точек в оттенках серого на 2D-плоскости мы хотим иметь x, y - позиции и цвет

## примеры данных



# Свойства распутывания - модульность

- **Модульность** измеряет, кодирует ли одна скрытая размерность не более одного фактора генерации данных.
- **Пример:** Когда изменение скрытого фактора  $z_i$  изменяет только один атрибут, например размер объекта, то он является **модульным**.
- **Контрпример.** Если изменение  $z_i$  меняет и цвет и размер, то он не модульный в этом смысле.

# Свойства распутывания - компактность или полнота

- **Компактность/полнота** измеряет, кодируется ли каждый фактор генерации данных одной скрытой размерностью.
- **Пример:** Полнота требует, чтобы атрибут изменялся только при изменении конкретного  $z_i$ . Для всех  $z_{j \neq i}$  атрибут (например, цвет) должен оставаться постоянным.
- **Контрпример.** Полнота - обратное модульности. Модульность по-прежнему выполняется, если оба  $z_i$  и  $z_j$  кодируют цвет, но такое представление не является компактным.

# Свойства распутывания - информативность (1)

- **Информативность** измеряет, могут ли значения всех факторов, генерирующих данные, быть декодированы линейным преобразованием. Распутанное представление должно охватывать все скрытые факторы (условие 1), и эта информация должна быть линейно декодируемой (условие 2).
- **Пример:** В 3D-сцене объекта с определенной формой, размером, положением и ориентацией все факторы соответствуют скрытым факторам, поэтому можно извлечь всю информацию, применив линейное преобразование, т.е.  $Z_{true} = AZ_{learned}$ . Т.е. может случиться так, что один  $Z_{learned,i}$  изменяет несколько факторов, но можно найти такую матрицу  $A$ , что получим факторы, для которых выполняется модульность.

# Свойства распутывания - информативность (2)

- **Информативность** измеряет, могут ли значения всех факторов, генерирующих данные, быть декодированы линейным преобразованием. Распутанное представление должно охватывать все скрытые факторы (условие 1), и эта информация должна быть линейно декодируемой (условие 2).
- **Контрпример.** Условие 1 нарушается, если, например, цвет не закодирован в латентном состоянии; а условие 2 не выполняется, если не существует такой матрицы  $A$ , для которой выполняется  $Z_{true} = Az_{learned}$  (например, существует нелинейное отображение в  $Z_{true}$ ).

# Распутывание с VAE (1)


- $\beta$ -VAE пытается решить сложную проблему - найти независимые порождающие факторы набора данных без учителя, чтобы получить факторизованную генеративную модель. Это - супер-проблема.
- Как  $\beta$ -VAE делает это? Гиперпараметр  $\beta$  управляет информационным латентным слоем в VAE, “поощряя” распутанные скрытые представления. Один из способов визуализировать это - использовать скрытые обходы (latent traversals).
- Скрытый обход - начинаем со случайно выбранного примера данных и пропускаем его через кодировщик VAE, получая скрытое представление  $z \in \mathbb{R}^N$  примера.

# Распутывание с VAE (2)

- Если скорректировать один элемент вектора  $z$ , сохранив фиксированными другие  $N - 1$  элементов, то можно создать множество скрытых вариаций, которые затем декодируются. Процедура повторяется для всех элементов  $z$ .
- Для воссоздания фигуры будем использовать простой набор данных, состоящий из изображений белой точки на черном фоне. Точка всегда одного размера, и единственное, что меняется, — это ее местоположение. Таким образом, есть два основных генерирующих фактора: координаты  $x$  и  $y$ .


# Просто VAE

## Обычный VAE



## Распутывающий VAE


## Скрытый обход (latent traversals)



# Распутывающий VAE с малым параметром (1)

- Скрытый обход для  $\beta$ -VAE, где значение  $\beta$  слишком малое.
- В этом случае латентный слой слишком широкий, и сеть не может создать эффективное скрытое представление.
- Сеть распределяет скрытое представление по четырем различным измерениям. Напомним, что существует только два порождающих фактора:  $x$  и  $y$ , поэтому двух скрытых элемента было бы достаточно.
- Более того, когда корректируется один скрытый элемент, выходные данные не всегда являются достоверными реконструкциями, некоторые из них даже показывают две точки.


## Распутывающий VAE с малым параметром (2)



Когда латентный слой большой, сеть свободно кодирует запутанное и неэкономное скрытое представление. Зеленые границы обозначают реконструкции с неизмененными скрытыми элементами.

# Распутывающий VAE с большим параметром


- Увеличим  $\beta$



Значение  $\beta$  слишком велико. Латентный слой слишком мал, что вынуждает сеть пытаться закодировать два порождающих фактора в одном скрытом элементе, сеть не может делать достаточно хорошие реконструкции

# Распутывающий VAE с “хорошим” параметром


- Имеется теперь скрытое пространство, в котором только два из пяти доступных измерений на самом деле что-то кодируют, и более того, они ортогональны.



# Распутывающий VAE с “хорошим” параметром

- Пострадали в отношении качества реконструкции (по сравнению с малым  $\beta$ ), но, это можно исправить.
- Нужно начинать с высокого значения  $\beta$  и уменьшать его во время обучения.
- Скрытый обход сети, обученной со значением  $\beta$ , скорректированным во время обучения. Распутанное представление кодируется с сохранением высокого качества реконструкции.

# Распутывающий VAE




Скрытый обход сети, обученной со значением  $\beta$ , скорректированным во время обучения. Распутанное представление кодируется с сохранением высокого качества реконструкции

# Снова деформирующий автокодер

- Деформирующий автокодер способен определять форму и внешний вид объекта как степени вариативности в изученном малоразмерном скрытом пространстве
- Архитектура состоит из
  - кодера, который кодирует входное изображение в два скрытых вектора (один – для формы, другой – для вида)
  - двух декодеров, принимающих векторы в качестве входных данных и выдающих сгенерированную текстуру и деформации
- Независимые декодеры необходимы для получения функций внешнего вида и деформации


# Структура (1)



## Структура (2)

- Сгенерированная пространственная информация используется для деформации текстуры к наблюдаемым координатам изображения
- DAE может восстановить входное изображение и в то же время определить форму и вид объекта как различные особенности
- Вся нейросеть тренируется без помощника на основе лишь простых потерь восстановления изображения

## Разрешенные деформации




- Допускаются только локально согласованная деформации (b)
  - Изменение относительных позиций пикселей (c) не допускается
  - Для этого позволяем декодеру деформации предсказывать горизонтальные и вертикальные приращения деформации ( $\nabla_x W$  и  $\nabla_y W$ )

## ДАЕ с заданной классификацией

- DAE с заданной классификацией учатся восстанавливать изображение и одновременно определяют форму и вид факторов вариативности, соответствующие определенному классу
  - Для реализации, вводят классифицирующую нейросеть, вход которой - третий скрытый вектор, используемый для кодирования класса. Это позволяет изучать смешанную модель, обусловленную классом вх. изобр.
  - Это улучшает эффективность и стабильность обучения, так как нейросеть учится разделять типы пространственной деформации, различные для каждого класса


## DAE с заданной классификацией



# Встроенный DAE

Для вычисления альбено и теней на портретных изображениях

Альбено - коэффициент диффузного отражения, то есть отношение светового потока, рассеянного плоским элементом поверхности во всех направлениях, к потоку, падающему на этот элемент



# Обучение (1)

$$E_{\text{DAE}} = E_{\text{Reconstruction}} + E_{\text{Warp}}$$

- Reconstruction loss and warping loss

$$E_{\text{Reconstruction}} = \|\text{Output} - \text{Input}\|^2,$$

$$E_{\text{Warp}} = E_{\text{Smooth}} + E_{\text{BiasReduce}}$$

- $E_{\text{Smooth}}$  штрафует быстро меняющиеся деформации, закодированные локальным полем деформации, измеряется как общая норма вариации горизонтальных и вертикальных деформаций
- $E_{\text{BiasReduce}}$  направлены на устранение любого систематического искажения, вносимого процессом подбора

# Обучение (2)

$$E_{\text{Smooth}} = \lambda_1 (\|\nabla W_x(x, y)\|_1 + \|\nabla W_y(x, y)\|_1)$$

- $\nabla W_x(x, y)$  и  $\nabla W_y(x, y)$  смещения по  $x$  и  $y$

$$E_{\text{BiasReduce}} = \lambda_2 (\|S_A - S_0\|^2 + \|W - W_0\|^2)$$

- тень  $S$  и альбето  $A$

# MNIST

- DAE способен успешно выявлять форму и внешний вид объектов во время обучения
- DAE с заданной классификацией дают наилучшие результаты как при восстановлении, так и при изучении внешнего вида объектов




(a) input



(b) reconstruction



(c) decoded appearance




(d) decoded deformation

# DAE в различных режимах (1)

- Наложение изображений без учителя.
- Изучение семантически важных множеств для формы и внешнего вида объектов.
- Внутренняя декомпозиция без учителя.
- Детектирование локализации без учителя.

## DAE в различных режимах (2)

## Восстановления MNIST с заданной классификацией



(a) input


(b) Reconstruction  
w/o classification

(c) Appearance  
w/o classification

(d) Reconstruction  
with classification


(e) Appearance  
with classification

Наложение изоб-ний ладоней без учителя



(a) – Входные изображения (b) – восстановленные изображения (c) – изображения текстур, деформированные с использованием среднего декодированной деформации (d) – среднее входное изображение (e) – средняя текстура

# Интерполяция освещения с помощью встроенного DAE



И так...

- DAE - специфическая архитектура, способная выявлять определенные факторы вариативности – в данном случае это форма и внешний вид объектов.
- Результаты работы DAE показывают, что она способна успешно выявлять факторы вариативности посредством применения архитектуры автокодеров

# Вопросы

?