

Машинное обучение (Machine Learning)

Диффузионные модели


Уткин Л.В.



Общее

- <https://lilianweng.github.io/posts/2021-07-11-diffusion-models/>
- Идея диффузионных моделей основана на идеях неравновесной термодинамики.
- Они определяют марковскую цепь шагов диффузии, чтобы медленно добавлять случайный шум к данным, а затем учатся обращать процесс диффузии вспять, чтобы создавать желаемые выборки данных из шума. В отличие от VAE, модели диффузии обучаются с помощью фиксированной процедуры, а скрытая переменная имеет высокую размерность (такую же, как исходные данные).

Отличие от других моделей



Прямой диффузионный процесс (1)

- Дана точка сгенерированная из реального распределения данных $\mathbf{x}_0 \sim q(\mathbf{x})$
- Определим прямой процесс диффузии, в котором поэтапно за T шагов добавляем небольшое количество гауссова шума к примеру, создавая последовательность зашумленных примеров $\mathbf{x}_1, \dots, \mathbf{x}_T$


Прямой диффузионный процесс (2)

- Размеры шага контролируются дисперсией $\{\beta_t \in (0, 1)\}_{t=1}^T$ которая указывает, сколько шума мы хотим добавить на одном шаге

$$q(\mathbf{x}_t | \mathbf{x}_{t-1}) = \mathcal{N}(\mathbf{x}_t; \sqrt{1 - \beta_t} \mathbf{x}_{t-1}, \beta_t \mathbf{I}),$$
$$q(\mathbf{x}_{1:T} | \mathbf{x}_0) = \prod_{t=1}^T q(\mathbf{x}_t | \mathbf{x}_{t-1})$$

- Точка $\mathbf{x}_0$ постепенно теряет свои отличительные черты по мере увеличения шага t .

Прямой диффузионный процесс (3)



Прямой диффузионный процесс (4)

- Замечательное свойство процесса - мы можем генерировать $\mathbf{x}_t$ на произвольном временном шаге t в явном виде, используя репараметризацию.
- Пусть $\alpha_t = 1 - \beta_t$ и $\bar{\alpha}_t = \prod_{i=1}^t \alpha_i$. Тогда

$$\begin{aligned}\mathbf{x}_t &= \sqrt{\alpha_t} \mathbf{x}_{t-1} + \sqrt{1 - \alpha_t} \epsilon_{t-1}; \epsilon_{t-1}, \epsilon_{t-2}, \dots \sim \mathcal{N}(\mathbf{0}, \mathbf{I}) \\ &= \sqrt{\alpha_t \alpha_{t-1}} \mathbf{x}_{t-2} + \sqrt{1 - \alpha_t \alpha_{t-1}} \bar{\epsilon}_{t-2}; \bar{\epsilon}_{t-2} \text{ объединяет 2 н.р.} \\ &= \dots \\ &= \sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon\end{aligned}$$

Итого

$$q(\mathbf{x}_t | \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \sqrt{\bar{\alpha}_t} \mathbf{x}_0, (1 - \bar{\alpha}_t) \mathbf{I})$$

Прямой диффузионный процесс (5)

- Напомним, что когда мы объединяем два норм. распред. с разной дисперсией $\mathcal{N}(\mathbf{0}, \sigma_1^2 \mathbf{I})$ и $\mathcal{N}(\mathbf{0}, \sigma_2^2 \mathbf{I})$, новое распределение $\mathcal{N}(\mathbf{0}, (\sigma_1^2 + \sigma_2^2) \mathbf{I})$.
- Здесь объединенное СКО равно
$$\sqrt{(1 - \alpha_t) + \alpha_t(1 - \alpha_{t-1})} = \sqrt{1 - \alpha_t \alpha_{t-1}}.$$
- Обычно можно делать больший шаг обновления, когда пример становится более шумным, поэтому $\beta_1 < \beta_2 < \dots < \beta_T$ и $\bar{\alpha}_1 > \dots > \bar{\alpha}_T$

Связь со стохастической градиентной динамикой Ланжевена (1)

- Динамика Ланжевена — это понятие из физики (стат. модел-е молекулярных систем)
- В сочетании со SGD стохастическая градиентная динамика Ланжевена создает примеры из плотности $p(\mathbf{x})$, используя только градиенты $\nabla_{\mathbf{x}} \log p(\mathbf{x})$ в марковской цепи обновлений:

$$\mathbf{x}_t = \mathbf{x}_{t-1} + \frac{\delta}{2} \nabla_{\mathbf{x}} \log q(\mathbf{x}_{t-1}) + \sqrt{\delta} \epsilon_t, \text{ где } \epsilon_t \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$$

где δ - размер шага.

Связь со стохастической градиентной динамикой Ланжевена (2)

- Когда $T \rightarrow \infty$, $\epsilon \rightarrow 0$, $\mathbf{x}_T$ определяется истинной плотностью $p(\mathbf{x})$.
- По сравнению со стандартным SGD стохастическая градиентная динамика Ланжевена вводит гауссов шум в обновления параметров, чтобы избежать коллапса в локальные минимумы.

Обратный диффузионный процесс (1)

- Если мы сможем обратить описанный выше процесс и произвести выборку из $q(\mathbf{x}_{t-1}|\mathbf{x}_t)$, мы сможем воссоздать истинную выборку из входного гауссовского шума $\mathbf{x}_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$.
- Если даже β_t достаточно мал, он также будет гауссовым.
- К сожалению, мы не можем просто оценить $q(\mathbf{x}_{t-1}|\mathbf{x}_t)$, т.к. для этого нужно использовать весь датасет, и поэтому нужно научить модель p_θ для аппроксимации этих условных вероятностей, чтобы запустить процесс обратной диффузии.

Обратный диффузионный процесс (2)

- К сожалению, мы не можем просто оценить $q(\mathbf{x}_{t-1}|\mathbf{x}_t)$, т.к. для этого нужно использовать весь датасет, и поэтому нужно научить модель p_θ для аппроксимации этих условных вероятностей, чтобы запустить процесс обратной диффузии.

$$p_\theta(\mathbf{x}_{0:T}) = p(\mathbf{x}_T) \prod_{t=1}^T p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t),$$

$$p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t) = \mathcal{N}(\mathbf{x}_{t-1}; \boldsymbol{\mu}_\theta(\mathbf{x}_t, t), \boldsymbol{\Sigma}_\theta(\mathbf{x}_t, t))$$

- “Обратная” условная вероятность поддается обработке, если она условна по $\mathbf{x}_0$

$$q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_{t-1}; \tilde{\boldsymbol{\mu}}(\mathbf{x}_t, \mathbf{x}_0), \tilde{\boldsymbol{\beta}}_t \mathbf{I})$$

Обратный диффузионный процесс (3)

- Используем правило Байеса

$$\begin{aligned} q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0) &= q(\mathbf{x}_t|\mathbf{x}_{t-1}, \mathbf{x}_0) \frac{q(\mathbf{x}_{t-1}|\mathbf{x}_0)}{q(\mathbf{x}_t|\mathbf{x}_0)} \\ &\propto \exp \left(-\frac{1}{2} \left(\frac{(\mathbf{x}_t - \sqrt{\alpha_t} \mathbf{x}_{t-1})^2}{\beta_t} \right. \right. \\ &\quad \left. \left. + \frac{(\mathbf{x}_{t-1} - \sqrt{\bar{\alpha}_{t-1}} \mathbf{x}_0)^2}{1 - \bar{\alpha}_{t-1}} - \frac{(\mathbf{x}_t - \sqrt{\bar{\alpha}_t} \mathbf{x}_0)^2}{1 - \bar{\alpha}_t} \right) \right) \end{aligned}$$

Обратный диффузионный процесс (4)

$$\begin{aligned}
 &= \exp \left(-\frac{1}{2} \left(\frac{\mathbf{x}_t^2 - 2\sqrt{\alpha_t}\mathbf{x}_t\mathbf{x}_{t-1} + \alpha_t\mathbf{x}_{t-1}^2}{\beta_t} \right. \right. \\
 &+ \left. \frac{\mathbf{x}_{t-1}^2 - 2\sqrt{\bar{\alpha}_{t-1}}\mathbf{x}_0\mathbf{x}_{t-1} + \bar{\alpha}_{t-1}\mathbf{x}_0^2}{1 - \bar{\alpha}_{t-1}} - \frac{(\mathbf{x}_t - \sqrt{\bar{\alpha}_t}\mathbf{x}_0)^2}{1 - \bar{\alpha}_t} \right) \Bigg) \\
 &= \exp \left(-\frac{1}{2} \left(\left(\frac{\alpha_t}{\beta_t} + \frac{1}{1 - \bar{\alpha}_{t-1}} \right) \mathbf{x}_{t-1}^2 \right. \right. \\
 &- \left. \left(\frac{2\sqrt{\alpha_t}}{\beta_t}\mathbf{x}_t + \frac{2\sqrt{\bar{\alpha}_{t-1}}}{1 - \bar{\alpha}_{t-1}}\mathbf{x}_0 \right) \mathbf{x}_{t-1} + C(\mathbf{x}_t, \mathbf{x}_0) \right) \Bigg) + C(\mathbf{x}_t, \mathbf{x}_0) \Bigg)
 \end{aligned}$$

$C(\mathbf{x}_t, \mathbf{x}_0)$ - некоторая функция, не включающая $\mathbf{x}_{t-1}$.

Репараметризация среднего и дисперсии

Следуя функции плотности Гаусса и репараметризации среднего значения и дисперсии ($\alpha_t = 1 - \beta_t$ и $\bar{\alpha}_t = \prod_{i=1}^t \alpha_i$):

$$\begin{aligned}\tilde{\beta}_t &= 1 / \left(\frac{\alpha_t}{\beta_t} + \frac{1}{1 - \bar{\alpha}_{t-1}} \right) = 1 / \left(\frac{\alpha_t - \bar{\alpha}_t + \beta_t}{\beta_t(1 - \bar{\alpha}_{t-1})} \right) \\ &= \frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t} \cdot \beta_t\end{aligned}$$

Обратный диффузионный процесс (6)

$$\begin{aligned}\tilde{\mu}_t(\mathbf{x}_t, \mathbf{x}_0) &= \left(\frac{\sqrt{\alpha_t}}{\beta_t} \mathbf{x}_t + \frac{\sqrt{\bar{\alpha}_{t-1}}}{1 - \bar{\alpha}_{t-1}} \mathbf{x}_0 \right) / \left(\frac{\alpha_t}{\beta_t} + \frac{1}{1 - \bar{\alpha}_{t-1}} \right) \\ &= \left(\frac{\sqrt{\alpha_t}}{\beta_t} \mathbf{x}_t + \frac{\sqrt{\bar{\alpha}_{t-1}}}{1 - \bar{\alpha}_{t-1}} \mathbf{x}_0 \right) \\ &\quad \times \frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t} \cdot \beta_t \\ &= \frac{\sqrt{\alpha_t}(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t} \mathbf{x}_t + \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1 - \bar{\alpha}_t} \mathbf{x}_0\end{aligned}$$

Обратный диффузионный процесс (7)

Так как $\mathbf{x}_0 = \frac{1}{\sqrt{\bar{\alpha}_t}}(\mathbf{x}_t - \sqrt{1 - \bar{\alpha}_t}\epsilon_t)$, то

$$\begin{aligned}\tilde{\mu}_t &= \frac{\sqrt{\alpha_t}(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t}\mathbf{x}_t + \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1 - \bar{\alpha}_t} \frac{1}{\sqrt{\bar{\alpha}_t}}(\mathbf{x}_t - \sqrt{1 - \bar{\alpha}_t}\epsilon_t) \\ &= \frac{1}{\sqrt{\alpha_t}}\left(\mathbf{x}_t - \frac{1 - \alpha_t}{\sqrt{1 - \bar{\alpha}_t}}\epsilon_t\right)\end{aligned}$$

ELBO - по аналогии с VAE

$$\begin{aligned} -\log p_{\theta}(\mathbf{x}_0) &\leq -\log p_{\theta}(\mathbf{x}_0) + D_{\text{KL}}(q(\mathbf{x}_{1:T}|\mathbf{x}_0) \| p_{\theta}(\mathbf{x}_{1:T}|\mathbf{x}_0)) \\ &= -\log p_{\theta}(\mathbf{x}_0) + \mathbb{E}_{\mathbf{x}_{1:T} \sim q(\mathbf{x}_{1:T}|\mathbf{x}_0)} \left[\log \frac{q(\mathbf{x}_{1:T}|\mathbf{x}_0)}{p_{\theta}(\mathbf{x}_{0:T})/p_{\theta}(\mathbf{x}_0)} \right] \\ &= -\log p_{\theta}(\mathbf{x}_0) + \mathbb{E}_q \left[\log \frac{q(\mathbf{x}_{1:T}|\mathbf{x}_0)}{p_{\theta}(\mathbf{x}_{0:T})} + \log p_{\theta}(\mathbf{x}_0) \right] \\ &= \mathbb{E}_q \left[\log \frac{q(\mathbf{x}_{1:T}|\mathbf{x}_0)}{p_{\theta}(\mathbf{x}_{0:T})} \right] \end{aligned}$$

ELBO - по аналогии с VAE

- Устанавливаем границу L_{VLB} . Пусть

$$L_{VLB} = \mathbb{E}_{q(\mathbf{x}_{0:T})} \left(\log \frac{q(\mathbf{x}_{1:T}|\mathbf{x}_0)}{p_\theta(\mathbf{x}_{0:T})} \right) \geq -\mathbb{E}_{q(\mathbf{x}_0)} \log p_\theta(\mathbf{x}_0)$$

- Также легко получить тот же результат, используя неравенство Йенсена. Пусть мы хотим минимизировать кросс-энтропию в качестве цели обучения:

$$\begin{aligned} L_{CE} &= -\mathbb{E}_{q(\mathbf{x}_0)} \log p_\theta(\mathbf{x}_0) \\ &= -\mathbb{E}_{q(\mathbf{x}_0)} \log \left(\int p_\theta(\mathbf{x}_{0:T}) d\mathbf{x}_{1:T} \right) \\ &= -\mathbb{E}_{q(\mathbf{x}_0)} \log \left(\int q(\mathbf{x}_{1:T}|\mathbf{x}_0) \frac{p_\theta(\mathbf{x}_{0:T})}{q(\mathbf{x}_{1:T}|\mathbf{x}_0)} d\mathbf{x}_{1:T} \right) \end{aligned}$$

Неравенство Йенсена

$$\begin{aligned} L_{\text{CE}} &= -\mathbb{E}_{q(\mathbf{x}_0)} \log \left(\mathbb{E}_{q(\mathbf{x}_{1:T}|\mathbf{x}_0)} \frac{p_{\theta}(\mathbf{x}_{0:T})}{q(\mathbf{x}_{1:T}|\mathbf{x}_0)} \right) \\ &\leq -\mathbb{E}_{q(\mathbf{x}_{0:T})} \log \frac{p_{\theta}(\mathbf{x}_{0:T})}{q(\mathbf{x}_{1:T}|\mathbf{x}_0)} \\ &= \mathbb{E}_{q(\mathbf{x}_{0:T})} \left[\log \frac{q(\mathbf{x}_{1:T}|\mathbf{x}_0)}{p_{\theta}(\mathbf{x}_{0:T})} \right] = L_{\text{VLB}} \end{aligned}$$

Неравенство Йенсена: $f(\sum_{i=1}^n q_i x_i) \leq \sum_{i=1}^n q_i f(x_i)$, если $f(x_i)$ - выпуклые и $q_1 + \dots + q_n = 1$, $q_i \geq 0$

Дальнейшее преобразование

Представим L_{VLB} как комбинацию нескольких членов KL-дивергенции и энтропии:

$$\begin{aligned} L_{VLB} &= \mathbb{E}_{q(\mathbf{x}_{0:T})} \left[\log \frac{q(\mathbf{x}_{1:T}|\mathbf{x}_0)}{p_\theta(\mathbf{x}_{0:T})} \right] \\ &= \mathbb{E}_q \left[\log \frac{\prod_{t=1}^T q(\mathbf{x}_t|\mathbf{x}_{t-1})}{p_\theta(\mathbf{x}_T) \prod_{t=1}^T p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t)} \right] \\ &= \mathbb{E}_q \left[-\log p_\theta(\mathbf{x}_T) + \sum_{t=1}^T \log \frac{q(\mathbf{x}_t|\mathbf{x}_{t-1})}{p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t)} \right] \\ &= \end{aligned}$$

Дальнейшее преобразование

$$\begin{aligned} &= \mathbb{E}_q \left[-\log p_\theta(\mathbf{x}_T) + \sum_{t=2}^T \log \frac{q(\mathbf{x}_t | \mathbf{x}_{t-1})}{p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)} + \log \frac{q(\mathbf{x}_1 | \mathbf{x}_0)}{p_\theta(\mathbf{x}_0 | \mathbf{x}_1)} \right] \\ &= \mathbb{E}_q \left[-\log p_\theta(\mathbf{x}_T) + \sum_{t=2}^T \log \left(\frac{q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0)}{p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)} \cdot \frac{q(\mathbf{x}_t | \mathbf{x}_0)}{q(\mathbf{x}_{t-1} | \mathbf{x}_0)} \right) \right. \\ &\quad \left. + \log \frac{q(\mathbf{x}_1 | \mathbf{x}_0)}{p_\theta(\mathbf{x}_0 | \mathbf{x}_1)} \right] = \end{aligned}$$

Дальнейшее преобразование

$$\begin{aligned} &= \mathbb{E}_q \left[\log \frac{q(\mathbf{x}_T | \mathbf{x}_0)}{p_\theta(\mathbf{x}_T)} \right. \\ &+ \left. \sum_{t=2}^T \log \frac{q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0)}{p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)} - \log p_\theta(\mathbf{x}_0 | \mathbf{x}_1) \right] \\ &= \mathbb{E}_q \left[\underbrace{D_{\text{KL}}(q(\mathbf{x}_T | \mathbf{x}_0) \parallel p_\theta(\mathbf{x}_T))}_{L_T} \right. \\ &+ \left. \sum_{t=2}^T \underbrace{D_{\text{KL}}(q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0) \parallel p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t))}_{L_{t-1}} - \underbrace{\log p_\theta(\mathbf{x}_0 | \mathbf{x}_1)}_{L_0} \right] \end{aligned}$$

Дальнейшее преобразование

$$L_{\text{VLB}} = L_T + L_{T-1} + \dots + L_0$$

где

$$L_T = D_{\text{KL}}(q(\mathbf{x}_T|\mathbf{x}_0) \parallel p_{\theta}(\mathbf{x}_T))$$

$$L_t = D_{\text{KL}}(q(\mathbf{x}_t|\mathbf{x}_{t+1}, \mathbf{x}_0) \parallel p_{\theta}(\mathbf{x}_t|\mathbf{x}_{t+1})), \quad 1 \leq t \leq T-1$$

$$L_0 = -\log p_{\theta}(\mathbf{x}_0|\mathbf{x}_1)$$

В итоге

- Каждый член KL в L_{VLB} (кроме L_0) сравнивает два распределения Гаусса, и поэтому они могут быть вычислены в явном виде.
- L_T является постоянной и может быть проигнорировано во время обучения, поскольку q не имеет обучаемых параметров и $\mathbf{x}_T$ является гауссовским шумом.

Параметризация потерь для обучения (1)

- Напомним, что нам нужно обучить нейронную сеть для аппроксимации условных распределений вероятностей в процессе обратной диффузии

$$p_{\theta}(\mathbf{x}_{t-1}|\mathbf{x}_t) = \mathcal{N}(\mathbf{x}_{t-1}; \boldsymbol{\mu}_{\theta}(\mathbf{x}_t, t), \boldsymbol{\Sigma}_{\theta}(\mathbf{x}_t, t))$$

- Хотим обучить $\boldsymbol{\mu}_{\theta}$, чтобы предсказывать

$$\tilde{\boldsymbol{\mu}}_t = \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{1 - \alpha_t}{\sqrt{1 - \bar{\alpha}_t}} \boldsymbol{\epsilon}_t \right)$$

Параметризация потерь для обучения (2)

- Поскольку $\mathbf{x}_t$ доступен в качестве входных данных во время обучения, мы можем репараметризовать член гауссовского шума, чтобы он предсказывал ϵ_t на основе входных данных $\mathbf{x}_t$ на шаге t :

$$\mu_{\theta}(\mathbf{x}_t, t) = \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{1 - \alpha_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_{\theta}(\mathbf{x}_t, t) \right)$$

- Отсюда

$$\mathbf{x}_{t-1} = \mathcal{N}(\mathbf{x}_{t-1}; \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{1 - \alpha_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_{\theta}(\mathbf{x}_t, t) \right), \Sigma_{\theta}(\mathbf{x}_t, t))$$

Параметризация потерь для обучения (3)

- L_t параметризуется, чтобы минимизировать разницу с $\tilde{\mu}$.

$$\begin{aligned} L_t &= \mathbb{E}_{\mathbf{x}_0, \epsilon} \left[\frac{1}{2 \|\boldsymbol{\Sigma}_{\theta}(\mathbf{x}_t, t)\|_2^2} \|\tilde{\mu}_t(\mathbf{x}_t, \mathbf{x}_0) - \mu_{\theta}(\mathbf{x}_t, t)\|^2 \right] \\ &= \mathbb{E}_{\mathbf{x}_0, \epsilon} \left[\frac{1}{2 \|\boldsymbol{\Sigma}_{\theta}\|_2^2} \left\| \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{1 - \alpha_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_t \right) \right. \right. \\ &\quad \left. \left. - \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{1 - \alpha_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_{\theta}(\mathbf{x}_t, t) \right) \right\|^2 \right] \\ &= \mathbb{E}_{\mathbf{x}_0, \epsilon} \left[\frac{(1 - \alpha_t)^2}{2 \alpha_t (1 - \bar{\alpha}_t) \|\boldsymbol{\Sigma}_{\theta}\|_2^2} \|\epsilon_t - \epsilon_{\theta}(\mathbf{x}_t, t)\|^2 \right] \\ &= \mathbb{E}_{\mathbf{x}_0, \epsilon} \left[\frac{(1 - \alpha_t)^2}{2 \alpha_t (1 - \bar{\alpha}_t) \|\boldsymbol{\Sigma}_{\theta}\|_2^2} \right. \\ &\quad \left. \times \|\epsilon_t - \epsilon_{\theta}(\sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon_t, t)\|^2 \right] \end{aligned}$$

Упрощение

- Обучение диффузионной модели лучше работает с упрощенной целевой функцией, которая игнорирует весовой коэффициент:

$$\begin{aligned} L_t^{\text{simple}} &= \mathbb{E}_{t \sim [1, T], \mathbf{x}_0, \epsilon_t} \left[\|\epsilon_t - \epsilon_\theta(\mathbf{x}_t, t)\|^2 \right] \\ &= \mathbb{E}_{t \sim [1, T], \mathbf{x}_0, \epsilon_t} \left[\|\epsilon_t - \epsilon_\theta(\sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon_t, t)\|^2 \right] \end{aligned}$$

- Окончательно $L_{\text{simple}} = L_t^{\text{simple}} + C$, где C - константа, независящая от θ .

Алгоритм обучения

Algorithm 1 Training

- 1: **repeat**
 - 2: $\mathbf{x}_0 \sim q(\mathbf{x}_0)$
 - 3: $t \sim \text{Uniform}(\{1, \dots, T\})$
 - 4: $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$
 - 5: Take gradient descent step on


$$\nabla_{\theta} \left\| \epsilon - \epsilon_{\theta}(\sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, t) \right\|^2$$
 - 6: **until** converged
-

Алгоритм генерации

Algorithm 2 Sampling


- 1: $\mathbf{x}_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$
 - 2: **for** $t = T, \dots, 1$ **do**
 - 3: $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ if $t > 1$, else $\mathbf{z} = \mathbf{0}$
 - 4: $\mathbf{x}_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{1-\alpha_t}{\sqrt{1-\bar{\alpha}_t}} \epsilon_{\theta}(\mathbf{x}_t, t) \right) + \sigma_t \mathbf{z}$
 - 5: **end for**
 - 6: **return** $\mathbf{x}_0$
-

Диффузия сжатых данных



<https://habr.com/ru/post/693298/>

Схема генерация изображения из текста



Еще описание

- Процессы диффузии и denoising происходят на скрытом векторе $\mathbf{z}$.
- Модель denoising представляет собой time-conditioned U-Net с блоками ResNet, дополненную механизмом cross-attention для обработки информации для создания изображений (например, метки классов, семантические карты, размытые варианты изображения) и для представления $\epsilon_{\theta}(\mathbf{x}_t, t)$.

Еще описание

- Если функция потерь для обычной диффузионной модели имеет вид:

$$L_t^{\text{simple}} = \mathbb{E}_{t \sim [1, T], \mathbf{x}_0, \epsilon_t} [\|\epsilon_t - \epsilon_\theta(\mathbf{x}_t, t)\|^2]$$

- то для латентной модели:

$$L_t^{\text{simple}} = \mathbb{E}_{t \sim [1, T], \mathcal{E}(\mathbf{x}), \epsilon_t} [\|\epsilon_t - \epsilon_\theta(\mathbf{z}_t, t)\|^2]$$

где $\mathcal{E}$ - кодер

Еще описание

- Это эквивалентно объединению представлений различных модальностей в модель с cross-attention. Каждый тип информации связан с доменным кодером τ_θ для проецирования входа y в промежуточное представление, которое может быть отображено в cross-attention элемент, $\tau_\theta(y)$:

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax} \left(\frac{\mathbf{QK}^\top}{\sqrt{d}} \right) \cdot \mathbf{V}$$

где $\mathbf{Q} = \mathbf{W}_Q^{(i)} \cdot \varphi_i(\mathbf{z}_i)$, $\mathbf{K} = \mathbf{W}_K^{(i)} \cdot \tau_\theta(y)$, $\mathbf{V} = \mathbf{W}_V^{(i)} \cdot \tau_\theta(y)$ и $\mathbf{W}_Q^{(i)} \in \mathbb{R}^{d \times d_\epsilon^i}$, $\mathbf{W}_K^{(i)}, \mathbf{W}_V^{(i)} \in \mathbb{R}^{d \times d_\tau}$, $\varphi_i(\mathbf{z}_i) \in \mathbb{R}^{N \times d_\epsilon^i}$, $\tau_\theta(y) \in \mathbb{R}^{M \times d_\tau}$

Почему U-Net?

- Модели диффузии тесно связаны с идеей автокодиров с шумоподавлением.
- Кроме того, U-Net-подобные архитектуры являются очень распространенной архитектурой для автокодиров изображений.
- Диффузионная U-Net может обуславливать свой вывод текстовыми эмбедингами через слои cross-attention, которые добавляются как к кодеру, так и к декодеру U-Net, обычно между блоками ResNet.

ДМ для данных с одним признаком

- Обучающие данные: $x \sim \mathcal{N}(\mu = 0, \sigma^2 = 1)$ (например, $[-0.5, 1.2, -1.3, 0.7, \dots]$).
- Прямой процесс (добавление шума)
 - Прямой процесс добавляет гауссовский шум в за T шагов:
 - Начнем с чистых данных x_0 (например, $x_0 = 1.0$).
 - На каждом временном шаге t добавляем шум:

$$x_t = \sqrt{1 - \beta_t} \cdot x_{t-1} + \sqrt{\beta_t} \cdot \epsilon_t$$

где β_t - параметр шума (например, $\beta_1 = 0.1$, $\beta_2 = 0.2, \dots$); $\epsilon_t \sim \mathcal{N}(0, 1)$ - шум.

Добавление шума

- $x_t = \sqrt{1 - \beta_t} \cdot x_{t-1} + \sqrt{\beta_t} \cdot \epsilon_t$
 β_t - параметр шума (например, $\beta_1 = 0.1$, $\beta_2 = 0.2$, ...); $\epsilon_t \sim \mathcal{N}(0, 1)$ - шум.
- Пример:

$$x_0 = 1.0$$

$$x_1 = \sqrt{0.9} \cdot 1.0 + \sqrt{0.1} \cdot (-0.2) \approx 0.89$$

$$x_2 = \sqrt{0.8} \cdot 0.89 + \sqrt{0.2} \cdot 0.3 \approx 0.94$$

$$\vdots$$

$$x_T \approx \mathcal{N}(0, 1) \quad (\text{чистый шум})$$

Обратный процесс (удаление шума)

- Научимся обращать процесс, предсказывая шум ϵ
- Для зашумленного x_t модель предсказывает: $\hat{\epsilon}_\theta(x_t, t)$
- Оцениваем x_{t-1} :

$$x_{t-1} = \frac{1}{\sqrt{1-\beta_t}} \left(x_t - \frac{\beta_t}{\sqrt{1-\bar{\alpha}_t}} \hat{\epsilon}_\theta(x_t, t) \right) + \sigma_t z, \quad z \sim \mathcal{N}(0, 1).$$

Пример:

$$x_T = 0.3 \quad \hat{\epsilon}_\theta(0.3, T) \approx -0.28$$

$$x_{T-1} \approx \frac{1}{\sqrt{0.9}} \left(0.3 - \frac{0.1}{\sqrt{0.9}} \cdot (-0.28) \right) \approx 0.38$$

$$\vdots$$

$$x_0 \approx 1.1$$

Обучение

Минимизируем ошибку предсказания шума:

$$\mathcal{L} = \|\epsilon - \hat{\epsilon}_{\theta}(x_t, t)\|^2$$

Пример:

$$x_0 = 1.0, \quad t = 2, \quad x_2 = 0.94, \quad \epsilon_2 = 0.3$$

$$\hat{\epsilon}_{\theta}(0.94, 2) = 0.4$$

$$\mathcal{L} = (0.3 - 0.4)^2 = 0.01$$

Сэмплирование (генерация)

- Начинаем с $x_T \sim \mathcal{N}(0, 1)$ (например, $x_T = -0.2$).
- Применяем обратный процесс для получения x_0 (например, $x_0 \approx -0.7$).
- Модель учится удалять шум, выполняя:
 - Разбиение процесса искажения на малые шаги
 - Обращение этих шагов посредством оценки шума

Обучение модели предсказания шума

- Loss function: обучить модель $\hat{\epsilon}_\theta$, которая предсказывает шум ϵ добавленный в ходе прямого процесса

$$\mathcal{L}(\theta) = \mathbb{E}_{t, x_0, \epsilon} [\|\epsilon - \hat{\epsilon}_\theta(x_t, t)\|^2]$$

- $x_0 \sim p_{\text{data}}$ чистая точка данных; $t \sim \mathcal{U}(\{1, \dots, T\})$ - случ. шаг времени; $\epsilon \sim \mathcal{N}(0, \mathbf{I})$ истинный шум
- $x_t = \sqrt{\alpha_t}x_0 + \sqrt{1 - \alpha_t}\epsilon$ - зашумленные данные
- $\alpha_t = \prod_{s=1}^t (1 - \beta_s)$

Алгоритм обучения

Algorithm 1 Training $\hat{\epsilon}_\theta(x_t, t)$

- 1: Инициализация параметров θ
 - 2: **for** each training iteration **do**
 - 3: $x_0 \sim p_{\text{data}}$ ▷ Sample clean data
 - 4: $t \sim \text{Uniform}(\{1, \dots, T\})$ ▷ Sample timestep
 - 5: $\epsilon \sim \mathcal{N}(0, 1)$ ▷ Sample noise
 - 6: Вычислить $x_t = \sqrt{\alpha_t}x_0 + \sqrt{1 - \alpha_t}\epsilon$
 - 7: $\hat{\epsilon}_\theta = \text{model}(x_t, t)$ ▷ Predict noise
 - 8: $\mathcal{L} = \|\epsilon - \hat{\epsilon}_\theta\|^2$ ▷ MSE loss
 - 9: Модифицировать θ с $\nabla_\theta \mathcal{L}$ ▷ Gradient descent
 - 10: **end for**
-

Архитектура модели

- Для одномерных данных можно использовать простую нейронную сеть:

$$\hat{\epsilon}_{\theta}(x_t, t) = f_{\theta}(x_t, \text{Embed}(t))$$

- $\text{Embed}(t)$ эмбединг временного шага (например, синусоидальное или обучаемое)
- f_{θ} обычно многослойный перцептрон (MLP)

Варианты параметров шума

- **Условие по временному шагу:** Критически важно для предсказания шума на разных этапах
- **Варианты шума:**
 - Линейный: $\beta_t = \beta_1 + (\beta_T - \beta_1) \frac{t-1}{T-1}$
 - Косинусный: $\alpha_t = \cos^2 \left(\frac{t}{T} \cdot \frac{\pi}{2} \right)$
- **Взвешивание потерь:** Можно по разному взвешивать различные временные шаги

Почему это работает

Модель учится оценивать компоненту шума в x_t :

$$x_t = \underbrace{\sqrt{\alpha_t}x_0}_{\text{signal}} + \underbrace{\sqrt{1 - \alpha_t}\epsilon}_{\text{noise}}$$

Минимизируя $\|\epsilon - \hat{\epsilon}_\theta\|^2$, модель неявно изучает распределение данных $p(x_0)$.

Пример для одномерных гауссовских данных

Для $x \sim \mathcal{N}(0, 1)$:

- При $t = 0$: $x_0 = 0.5$ (чистая выборка)
- При $t = 50$: $x_{50} = 0.1$ с $\epsilon = -0.3$
- Модель должна предсказать: $\hat{\epsilon}_{\theta}(0.1, 50) \approx -0.3$

в обратном процессе

 σ_t

- В обратном процессе σ_t - стандартное отклонение шума, добавляемого на этапе удаления шума при оценке x_{t-1} по x_t .
- Уравнение обратного процесса
- Оценка x_{t-1} задаётся формулой:

$$x_{t-1} = \underbrace{\frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \hat{\epsilon}_\theta(x_t, t) \right)}_{\text{Детерминированная часть}} + \underbrace{\sigma_t z}_{\text{Стохастическая часть}}$$

$z \sim \mathcal{N}(0, \mathbf{I})$ случайный шум; σ_t управляет величиной стохастичности

Распространенные выборы для

 σ_t

- DDPM (Denoising Diffusion Probabilistic Model, оригинальный):

$$\sigma_t = \sqrt{\beta_t} \quad (1)$$

Соответствует дисперсии прямого процесса.

- Улучшенный DDPM:

$$\sigma_t = \sqrt{\frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t} \beta_t} \quad (2)$$

Минимизирует дисперсию обратного процесса для улучшения качества выборки.

Ключевые свойства

- При $\sigma_t > 0$: Процесс стохастический (генерирует разнообразные выборки)
- При $\sigma_t = 0$: Процесс становится детерминированным (случай DDIM, Denoising Diffusion Implicit Models)
- Выводится из истинного обратного распределения $q(x_{t-1}|x_t, x_0)$

Значение получается из моделирования:

$$q(x_{t-1}|x_t, x_0) = \mathcal{N}(x_{t-1}; \tilde{\mu}_t(x_t, x_0), \tilde{\beta}_t \mathbf{I}), \quad \sigma_t = \sqrt{\tilde{\beta}_t}$$

Практические следствия

- Большие σ_t : Больше разнообразия, но ниже качество
- Меньшие σ_t : Выше точность, но меньше вариаций
- Пример (DDPM)

- Для линейного графика с $\beta_t = 0.1$ при $t = 5$:

$$\sigma_5 = \sqrt{0.1} \approx 0.316$$

- Обновление принимает вид:

$$x_4 = \text{Детерминированная часть} + 0.316 \cdot z$$

Вопросы

?