

# Машинное обучение: Объяснительный ИИ (Explainable AI (XAI) or ML)

## Объяснительный ИИ (Explainable AI or ML)

Уткин Л.В.

Санкт-Петербургский политехнический университет Петра Великого




# Для начала...

*“Some things in life are too complicated to explain in any language.”*


*Haruki Murakami*

# Что лучше?




- “модель предсказывает, что это - кот с вероятностью 0.98”
- “модель предсказывает, что это - кот с вероятностью 0.98, так как у него есть шерсть, усы, когти, уши определенной формы”
- как это показать?

# Что такое визуальное объяснение?




R.C. Fong, A. Vedaldi. Interpretable Explanations of Black Boxes by Meaningful Perturbation, IEEE International Conference on Computer Vision, 2017

# Что лучше?



# Модели для объяснения (основные) и объяснительные



# Прозрачность, интерпретация, объяснение

- **Прозрачность (transparency)**: основная модель
  - противоположность “черному ящику”; механизм работы модели известен
  - **данные не используются**
- **Интерпретация (interpretability)**: рассматривает основную модель вместе с данными
  - маски или heatmaps показывают значимые признаки
  - **данные всегда используются**
- **Объяснение (explainability)**: рассматривает основную модель, данные и участие человека
  - объяснения д.б. интерпретируемы, т.е., давать качественное понимание связи между вх. и вых. данными
  - **цель - объяснить, инструмент - интерпретация**

# Критерии для методов интерпретации


- ① Intrinsic - внутренняя интерпретируемость - использование модели МО, которая интерпретируется (линейные модели, модели на основе деревьев)
- ② Post hoc - объяснение после обучения основной модели
- ③ Model-specific or model-agnostic
- ④ Local or global

# Критерии (model-specific or model-agnostic)

- Специфичные для модели методы интерпретации специфичны зависят исключительно от каждой модели. Это могут быть коэффициенты, p-values, оценки AIC, правила из дерева решений и так далее.
- Независимые от модели методы интерпретации (агностические) могут использоваться для любой модели МО. Работают путем анализа (и возмущений входов) признаков пар вход-выход.
- Эти методы не имеют доступа к каким-либо внутренним компонентам модели, таким как веса, ограничения или допущения.

# Post-hoc и model-based интерпретация

- **Post-hoc интерпретация** - объяснение после обучения основной модели, пример - метод LIME
- **Model-agnostic** - Агностические модели
- **Model-based** интерпретация позволяет “вмешиваться” в процесс обучения



# Post-hoc интерпретация: локальная и глобальная

- ① **Локальная** - методы интерпретации сфокусированы на отдельном примере и результате его классификации
- ② **Глобальная** - методы интерпретации сфокусированы на значимых признаках всего множества данных (похоже на отбор признаков)

# Глобальная интерпретация


- Ответы на вопросы:
  - Как модель делает прогнозы?
  - Как подмножества признаков влияют на решения модели?
- Глобальная интерпретируемость - это способность объяснять и понимать решения модели на полном наборе данных.

# Локальная интерпретация

- Ответы на вопросы:
  - Почему модель принимает конкретное решение для одного примера?
  - Почему модель принимает конкретные решения для группы примеров?
- Для локальной интерпретируемости рассматриваем модель как черный ящик.

# Общая идея локальной интерпретации

Необходимо построить модель (метод) объяснения (объяснитель) для “основной” модели МО (глубокая нейронная сеть, случайный лес, SVM и т.д.), которая аппроксимирует основную модель в окрестности объяснимого примера и принадлежит множеству “простых” моделей, которые интерпретируются (линейные модели, деревья решений)



# Общая модель локальной интерпретации

- Основная модель реализует функцию  $f : \mathbb{R}^m \rightarrow \mathbb{R}^D$ , например, в классификации  $f(\mathbf{x})$  - вероятность того, что  $\mathbf{x}$  принадлежит опред. классу
- Объяснение - это модель  $g \in G$ ,  $G$  - класс интерпретируемых моделей (линейные модели, деревья решений)
- Задача оптимизации:

$$\min_{g \in G} \{L(f, g, \theta) + \Omega(g)\}$$

- $L(f, g, \theta)$  - мера того, как неточна  $g$  в аппр-ции  $f$
- $\theta$  - вектор параметров;  $\Omega(g)$  - регуляризатор

# Интерпретируемые модели


- **Линейная регрессия**
- **Логистическая регрессия**
- **Деревья решений**
- **GLM (Лассо, гребневая регрессия, эластичная сеть)**
- **К ближайших соседей**

# Почему линейная регрессия и деревья решений?

- Линейная регрессия


$$g(\mathbf{x}) = a_1x_1 + a_2x_2 + \dots + a_mx_m$$

- Деревья решений



# Метод LIME (Local Interpretable Model-agnostic Explanations)

- 1 Основная идея - предположение, что модель **линейная в окрестности анализируемой точки**
- 2 Вторая идея - возмущение признаков анализируемой точки для генерации новых данных
- 3 Используя основную модель, находится прогноз ( $y = f(x)$ ) для каждой сгенерированной точки  $x$  и образуется **новый датасет**
- 4 Используя новый датасет, метод **ЛАССО** определяет **значимые признаки**



## Метод LIME (3)

- LIME минимизирует функцию

$$\xi = \arg \min_{g \in G} L(f, g, \pi_X) + \Omega(g)$$

- $g$  - объяснительная модель для оригинальной модели  $f$ ;  $\pi_X$  - веса в виде ядер

$$g(z) = \phi_0 + \sum_{i=1}^M \phi_i z_i$$

- Local Interpretable Model-agnostic Explanations  
(Ribeiro, Singh, Guestrin, 2016)
- **Агностицизм:** LIME не делает никаких предположений относительно модели, прогноз которой объясняется, для него модель как «черный ящик»
- **Интерпретируемость:** LIME использует представление данных (называемое интерпретируемым представлением), которое отличается от исходного пространства признаков
- **Локальность:** LIME дает объяснение в окрестности примера, который хотим объяснить.

# LIME (пример)



(a) Original Image



(b) Explaining *Electric guitar*



(c) Explaining *Acoustic guitar*




(d) Explaining *Labrador*

Объяснение вариантов классификации. Три основных прогнозируемых класса: “Electric Guitar” ( $p = 0.32$ ), “Acoustic guitar” ( $p = 0.24$ ) и “Labrador” ( $p = 0.21$ )

# LIME (проблемы)

- ① Суперпиксели
- ② Существенная нелинейность в локальной области



- ③ Возмущения изображений, текстовые данные


# Метод SHAP

- Значимости SHAP основаны на числах Шепли, концепции из теории игр
- В теории игр нужны: игра и несколько игроков
- В машинном обучении:
  - «игра» воспроизводит выход модели
  - «игроки» - это признаки, включенные в модель
- Шепли количественно оценивает вклад каждого игрока в игру
- SHAP количественно оценивает вклад каждого признака в прогноз

# SHAP - множество мощности признаков (1)

- Модель машинного обучения: предсказывает доход человека, зная его возраст, пол и работу.
- Числа Шепли основаны на идее, что результат каждой возможной комбинации (или коалиции) игроков должен учитываться для определения важности отдельного игрока.
- В примере это соответствует каждой возможной комбинации  $f$  признаков ( $f \in \{0, 1, \dots, F\}$ ,  $F = 3$ ).

# SHAP - множество мощности признаков (2)




Каждый узел - коалиция признаков, каждое ребро - включение признака, отсутствующего в предыдущей коалиции, 8 коалиций

# SHAP - множество мощности признаков (3)

- SHAP требует обучения отдельной модели прогнозирования для каждой отдельной коалиции, то есть  $2^F$  моделей
- Модели полностью эквивалентны друг другу в том, что касается их гиперпараметров и их обучающих данных (которые представляют собой полный набор данных)
- Единственное, что меняется, это набор признаков, включенных в модель.

# SHAP - множество мощности признаков (4)

Пусть 8 регрессионных моделей дали 8 прогнозов для  $x_0$



# SHAP - маргинальный эффект

- Два узла, соединенные ребром, различаются только одним элементом в том смысле, что нижний имеет точно такие же признаки, что и верхний, плюс дополнительный признак, которого не было у верхнего
- Разрыв между прогнозами двух связанных узлов может быть вменен эффекту этого дополнительного признака
- Это называется «маргинальным вкладом» признака
- И так, каждое ребро - маргинальный вклад, вносимый признаком

## SHAP - снова пример


- Представим, что мы находимся в узле 1 (модель без признаков)
- Эта модель предсказывает средний доход от всех обучающих наблюдений: \$50 тыс.
- Если перейдем к узлу 2 (модель только с одним признаком - Age, прогноз для  $x_0$ : \$40 тыс.
- Это означает, что знание Age  $x_0$  снизило наш прогноз на \$10 тыс.
- Т.о. маргинальный вклад Age в модель, содержащую только Age в качестве признака: -10к \$

$$\begin{aligned} \text{MC}_{\text{Age}, \{\text{Age}\}}(x_0) &= \text{Predict}_{\{\text{Age}\}}(x_0) - \text{Predict}_{\emptyset}(x_0) \\ &= 40 - 50 = -10 \end{aligned}$$

# SHAP - снова пример

- Чтобы получить общий вклад  $Age$  на конечную модель (то есть значение SHAP  $Age$  для  $x_0$ ), необходимо учитывать маргинальный вклад  $Age$  во всех моделях, где присутствует  $Age$ , т.е. рассмотреть все ребра, соединяющие два узла, так что:
  - верхний не содержит  $Age$
  - нижний содержит  $Age$ .

# SHAP - снова пример



# SHAP - снова пример

Все маргинальные вклады затем суммируются с весами:

$$\begin{aligned}\text{SHAP}_{\text{Age}}(x_0) &= w_1 \times \text{MC}_{\text{Age}, \{\text{Age}\}}(x_0) \\ &+ w_2 \times \text{MC}_{\text{Age}, \{\text{Age}, \text{Gender}\}}(x_0) \\ &+ w_3 \times \text{MC}_{\text{Age}, \{\text{Age}, \text{Job}\}}(x_0) \\ &+ w_4 \times \text{MC}_{\text{Age}, \{\text{Age}, \text{Gender}, \text{Job}\}}(x_0)\end{aligned}$$

где  $w_1 + w_2 + w_3 + w_4 = 1$

# SHAP - веса ребер

- Сумма весов всех маргинальных вкладов в модели с 1 признаком должна равняться сумме весов всех маргинальных вкладов в модели с двумя признаками и так далее ...
- Т.е. сумма всех весов в том же «ряду» должно равняться сумме всех весов в любом другом «ряду»
- В примере это означает:  $w_1 = w_2 + w_3 = w_4$
- Все веса маргинальных вкладов в  $f$ -признаковой модели должны быть равны друг другу для каждого  $f$
- Т.е. все ребра одного «ряда» должны быть равны друг другу
- В примере это означает:  $w_2 = w_3$
- $w_1 = 1/3, w_2 = 1/6, w_3 = 1/6, w_4 = 1/3$

# SHAP - веса ребер

- Спойлер: вес ребра обратно пропорционален общему количеству ребер в одном «ряду».
- Или, что то же самое, вес маргинального вклада в модель  $f$  признаков является обратной величиной числа возможных маргинальных вкладов во все модели  $f$  признаков.

# SHAP - веса ребер

- Каждая модель  $f$  признаков имеет  $f$  маргинальных вкладов (по одному на каждый признак)
- Достаточно подсчитать число возможных моделей  $f$  признаков и умножить его на  $f$ .
- Т.о. все сводится к подсчету количества возможных моделей  $f$  признаков при заданном  $f$  и знании того, что общее количество признаков равно  $F$
- **Это - определение биномиального коэффициента!**

# SHAP - веса ребер


- Итог: количество всех маргинальных вкладов всех моделей  $f$  признаков (количество ребер в каждой «строке») - равно:

$$f \times C_F^f$$

- Обратная величина и есть вес маргинального вклада в модель  $f$  признаков

# SHAP - веса ребер

	N. of Nodes $\binom{F}{f}$	N. of Edges $f \times \binom{F}{f}$
$f = 0$	1	
$f = 1$		3
	3	
$f = 2$		6
	3	
$f = 3$	1	3
Sum	$2^F = 8$	$F \times 2^{F-1} = 12$



# SHAP - снова пример

$$\begin{aligned} \text{SHAP}_{Age}(x_0) &= [1 \cdot C_3^1]^{-1} \times \text{MC}_{Age,\{Age\}}(x_0) \\ &\quad + [2 \cdot C_3^2]^{-1} \times \text{MC}_{Age,\{Age, Gender\}}(x_0) \\ &\quad + [2 \cdot C_3^2]^{-1} \times \text{MC}_{Age,\{Age, Job\}}(x_0) \\ &\quad + [3 \cdot C_3^3]^{-1} \times \text{MC}_{Age,\{Age, Gender, Job\}}(x_0) \\ &= \frac{1}{3}(-10) + \frac{1}{6}(-9) + \frac{1}{6}(-15) + \frac{1}{3}(-12) = -11.33\$ \end{aligned}$$

# Shapley Values (1)

$$\text{SHAP}_{feature}(x) = \sum_{set: feature \in set} \left[ |set| \times C_F^{|set|} \right]^{-1} \times [\text{Predict}_{set}(x) - \text{Predict}_{set \setminus feature}(x)]$$

$$\phi_i = \sum_{S \subseteq F \setminus \{i\}} \frac{|S|! (|F| - |S| - 1)!}{|F|!} [f_{S \cup \{i\}}(x_{S \cup \{i\}}) - f_S(x_S)]$$

- $|F|$  - размер полной коалиции;  $S$  - подмножество коалиции, которое не включает игрока  $i$ , а  $|S|$  - размер  $S$ ,  $S!$  - число перестановок множества  $S$
- В квадратных скобках: «насколько больше выигрыш, когда мы добавляем игрока  $i$  к подмножеству  $S$ »

## Shapley Values (2)

- А как теперь с признаками?
- Вклад  $i$ -го признака:

$$\phi_i = \sum_{z' \subseteq x'} \frac{|z'|!(M - |z'| - 1)!}{M!} [f_x(z') - f_x(z' \setminus i)]$$

- $M$  - общее число признаков;  $z'$  - подмножество признаков, которое является объяснением
- Оцениваем значение модели с и без  $i$ -го признака ( $f_x(z')$  и  $f_x(z' \setminus i)$ )

# Shapley Values - снова пример

- $\text{SHAP}_{Age}(x_0) = -11.33$ ,  $\text{SHAP}_{Gender}(x_0) = -2.33$ ,  
 $\text{SHAP}_{Job}(x_0) = 46.66$
- Сумма = + \$33 тыс. В точности равно разнице между выходом всей модели (\$83 тыс.) и выходом пустой модели без признаков (\$50 тыс.)
- **Фундаментальная характеристика** чисел SHAP: сумма чисел SHAP каждого признака наблюдения дает разность между прогнозом модели и нулевой моделью (**SHapley Additive exPlanations**)

# Объяснения примером (example-based) (1)

- Методы выбирают пример (не признаки) из датасета для объяснения поведения основной модели
- Имеют смысл, если можно представить пример данных в виде понятном человеку
- Используют **прототипы классов**
- **k-ближайших соседей:**  $X$  классифицируется как  $y$ , так как  $A$ ,  $B$  и  $C$  из  $u$  аналогичны  $X$

# Метод возмущений

$\hat{\mathbf{x}} = \mathbf{x} + \delta$ ,  $\delta$  - вектор возмущений (случайных или вычисляемых)



Ships 70%, Cows 30%  
Birds 0%, People 0%




Perturbation




Birds 90%, People 10%  
Ships 0%, Cows 0%

# Counterfactual объяснения (гипотетические, противопоставления)

- Counterfactual - наименьшие изменения значений признаков, которые изменяют класс примера
- “Ваш запрос на кредит отклонен, так как ваш доход \$30,000 и ваш баланс \$200. Если бы ваш доход был \$35,000 и ваш текущий баланс был \$400, то ваш запрос был бы одобрен”



Step 1: Generation



Step 2: Feature Selection

# Counterfactuals (1)

- Обычно спрашивают, не почему был сделан определенный прогноз, а почему этот прогноз был сделан вместо другого прогноза.
- Для прогноза стоимости дома человека может интересовать, почему прогнозируемая цена была выше по сравнению с более низкой ценой, которую он ожидал.
- Когда заявка на кредит отклонена, меня не интересует, почему отказ. Меня интересуют факторы моей заявки, которые должны измениться, чтобы она была принята.
- Противоречивые объяснения легче понять, чем полные объяснения.

## Counterfactuals (2)

- Врач задается вопросом: «Почему лечение не сработало на пациенте?»
- Полное объяснение, почему лечение не работает, включает: пациент болеет с 10 лет, 11 генов сверхэкспрессированы, что делает болезнь более тяжелой, организм пациента разрушается, лекарство неэффективно
- Сравнительное объяснение - отвечает на вопрос по сравнению с другим пациентом, для которого препарат работал, может быть проще: у пациента есть комбинация генов, которые делают лекарство неэффективным, по сравнению с другим пациентом
- Лучшее объяснение - это то, что подчеркивает наибольшую разницу между объектом интереса и “эталонным” объектом


## Counterfactuals (3)

- Counterfactuals - наименьшие изменения значений признаков, которые изменяют класс примера
- Counterfactual  $\mathbf{z}$  для примера  $\mathbf{x}$  определяется решением задачи оптимизации:


$$\min_{\mathbf{z} \in \mathbb{R}^m} L(f(\mathbf{z}), f(\mathbf{x})) + C\theta(\mathbf{z}, \mathbf{x})$$

- $L(\cdot, \cdot)$  - функция потерь, устанавливающая связь между выходами основной модели;
- $\theta(\cdot, \cdot)$  - штрафное слагаемое "против" больших отклонений  $\mathbf{z}$  от  $\mathbf{x}$ , например, расстояние между  $\mathbf{z}$  и  $\mathbf{x}$ ;
- $C > 0$  - параметр

# Counterfactuals (4)



Step 1: Generation



Step 2: Feature Selection


# Глобальная интерпретация - feature importance

- Значимость признаков - какие признаки оказывают наибольшее влияние на прогнозируемые значения?
- Алгоритм: значимость перестановок (permutation importance)
  - 1 Получить обученную модель и записать признаки в виде таблицы (столбец - признак)
  - 2 Перемешать значения в одном столбце, сделать прогнозы, используя полученный набор данных. Снижение точности - значимость признака, который перемешали.
  - 3 Вернуться к исходной таблице (отмена перемешивания из шага 2). Повторить шаг 2 со следующим столбцом в таблице, пока не будут найдены значимости каждого столбца.


# Глобальная интерпретация - Partial Dependence Plot

- Значимость признаков показывает, какие признаки больше всего влияют на прогнозы, график частичной зависимости показывает, как признак влияет на прогнозы
- График частичной зависимости показывает, какая зависимость между признаком и выходом: линейная, монотонная или более сложная

# График частичной зависимости (пример 1)



# График частичной зависимости (пример 2 - взаимодействие признаков)



# График частичной зависимости

- Частичная зависимость:

$$f_{x_S}(x_S) = \mathbb{E}_{x_C} [f(x_S, x_C)] = \int f(x_S, x_C) d\mathbb{P}(x_C)$$

- $x_S$  - множество признаков, для которых график частичной зависимости определяется
- $x_C$  - все другие признаки, используемые в модели  $f$ ;  
 $x = x_S || x_C$  (конкатенация)
- Частичная зависимость работает путем маргинализации выходных данных модели  $f$  по распределению признаков  $x_C$ , так что оставшаяся функция показывает связь между  $x_S$  и прогнозом

# График частичной зависимости

- Частичная зависимость по данным из датасета:

$$f_{x_S}(x_S) = \frac{1}{n} \sum_{i=1}^n f(x_S, x_{C_i})$$

- $x_{C_i}$  - фактические значения признаков из датасета, в которых мы не заинтересованы
- Используемое предположение: признаки  $x_S$  не коррелируют с признаками  $x_C$

# Чтобы закончить...

*"Look deep into nature, and then you will understand everything better."*

***Albert Einstein***

# Вопросы

Вопросы — ?